

# Модели согласования скрытого пространства в задаче прогнозирования\*

Ф. Р. Яушев<sup>1</sup>, Р. В. Исаченко<sup>2</sup>, В. В. Стрижов<sup>3</sup>

**Аннотация:** В работе исследуется задача прогнозирования сложной целевой переменной. Под сложностью подразумевается наличие зависимостей, линейных или нелинейных. Предполагается, что исходные данные гетерогенны. Это значит, что пространства независимой и целевой переменных имеют разную природу. Предлагается построить предсказательную модель, которая учитывает зависимость в исходном пространстве независимой переменной, а также в пространстве целевой переменной. Согласование моделей предлагается проводить в низкоразмерном пространстве. В качестве базового алгоритма используется метод проекции в скрытое пространство (PLS). В работе проводится сравнение линейного PLS и предложенных нелинейных моделей. Сравнение проводится на гетерогенных данных в пространствах высокой размерности.

**Ключевые слова:** прогнозирование; модель частичных наименьших квадратов; задача восстановления; согласование скрытого пространства

**DOI:** 00.00000/0000000000000000

---

\*Статья содержит результаты проекта «Математические методы интеллектуального анализа больших данных», выполняемого в рамках реализации программы Центра компетенций Национальной технологической инициативы «Центр хранения и анализа больших данных», поддерживаемого Министерством науки и высшего образования Российской Федерации по договору МГУ им. М. В. Ломоносова с Фондом поддержки проектов Национальной технологической инициативы от 11.12.2018 № 13/1251/2018. Работа выполнена при поддержке РФФИ (проекты 19-07-01155, 19-07-00875).

<sup>1</sup>Московский физико-технический институт, fyaush@mail.ru

<sup>2</sup>Московский физико-технический институт, roman.isachenko@phystech.edu

<sup>3</sup>Вычислительный центр имени А. А. Дородницына Федерального исследовательского центра «Информатика и управление» Российской академии наук, Московский физико-технический институт, strijov@phystech.edu

# 1 Введение

В данной работе решается задача прогнозирования целевой переменной с наличием зависимостей. Трудность задачи в том, что исходные данные имеют высокую размерности и в пространствах целевой и независимой переменных есть скрытые зависимости. Чрезмерно высокая размерность пространств и наблюдаемая множественная корреляция приводят к неустойчивости прогностической модели. Для решения задачи предлагается построить модель, которая бы учитывала обе эти зависимости. Она переводит данные в низкоразмерные пространства и согласование данных происходит в полученном скрытом пространстве.

Метод проекции в скрытое пространство (Projection to Latent Space, PLS) [1, 2] восстанавливает зависимости между двумя наборами данных. Он применяется в биоинформатике, медицине, социальных науках [3–6]. Алгоритм PLS строит матрицу совместного описания признаков и целевой переменной. Полученное пространство является низкоразмерным. Это позволяет получить простую, точную и устойчивую прогностическую модель. Наряду с PLS используется метод канонического анализа корреляций (Canonical Correlation Analysis, CCA) [7]. Метод CCA применяется для поиска зависимостей между двумя наборами данных и получения их низкоразмерного представления [8, 9]. Метод CCA максимизирует корреляции, а метод PLS — ковариации. Обзор и сравнение CCA и PLS приводится в [1]. Линейные методы PLS и CCA игнорируют сложные нелинейные зависимости.

Задачи, в которых между данными существует нелинейная зависимость, описаны в работе [2]. Аппроксимация этой зависимости линейной моделью PLS приводит к неудовлетворительным результатам. Разработаны нелинейные модификации PLS [10–12] и CCA [13, 14]. Например, модель Deep CCA [13] преобразует исходные данные с помощью нейронной сети таким образом, что результирующее представление становится согласованным. Метод Deep CCA используется для генерации текстового описания по изображениям в работе [15].

В данной работе исследуется сложность моделей для данных со сложноорганизованной целевой переменной. Для учета зависимостей в целевом пространстве используются проекции в скрытое пространство с помощью моделей PLS и CCA. В случае наличия существенно нелинейных зависимостей между независимой и целевой переменными сложность линейной модели оказывается недостаточной. В работе предлагаются методы согласования проекций для нелинейных моделей.

В работе проведено два эксперимента. Первый направлен на сравнение эффективности Deep CCA и CCA на задаче классификации зашумленных цифровых изображений MNIST [16]. Во втором эксперименте используется набор данных, полученный делением каждого изображения из MNIST на левую и правую части. На задаче регрессии правой части изображения по левой проводится сравнение нелинейных моделей с применением автоэнкодеров, моделей без преобразования данных и линейного PLS. На основании полученных результатов сделан вывод о точности и сложности нелинейных алгоритмов и о целесообразности использования той или иной модели.

## 2 Постановка задачи

Задана выборка  $(\mathbf{X}, \mathbf{Y})$ , где  $\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n]^\top \in \mathbb{R}^{n \times m}$  — матрица независимых переменных,  $\mathbf{Y} = [y_1, \dots, y_n]^\top \in \mathbb{R}^{n \times k}$  — матрица целевых переменных. Предполагается, что между  $\mathbf{X}$  и  $\mathbf{Y}$  существует зависимость

$$\mathbf{Y} = f(\mathbf{X}) + \boldsymbol{\varepsilon}, \quad (1)$$

где  $f : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}^{n \times k}$  — функция регрессионной зависимости,  $\boldsymbol{\varepsilon}$  — матрица регрессионных ошибок. Необходимо восстановить зависимость  $f$  по заданной выборке.

### 2.1 Линейная регрессия

Предположим, что зависимость (1) линейна. Требуется найти эту зависимость:

$$\mathbf{Y} = f(\mathbf{X}) + \boldsymbol{\varepsilon} = \mathbf{X}\mathbf{W}^\top + \boldsymbol{\varepsilon}, \quad (2)$$

где  $\mathbf{W} \in \mathbb{R}^{k \times m}$  — матрица параметров модели.

Оптимальные параметры определяются минимизацией функции потерь. Используется квадратичная функция потерь

$$\mathcal{L}(\mathbf{W}|\mathbf{X}, \mathbf{Y}) = \left\| \begin{matrix} \mathbf{Y} \\ n \times k \end{matrix} - \begin{matrix} \mathbf{X} \\ n \times m \end{matrix} \cdot \begin{matrix} \mathbf{W}^\top \\ m \times k \end{matrix} \right\|_2^2 \rightarrow \min_{\mathbf{W}}. \quad (3)$$

Решение задачи (3) имеет вид

$$\mathbf{W} = \mathbf{Y}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}.$$

Линейная зависимость столбцов матрицы  $\mathbf{X}$  приводит к неустойчивости решения задачи минимизации (3), так как в этом случае матрица  $\mathbf{X}^\top \mathbf{X}$  является плохо обусловленной. Для борьбы с линейной зависимостью используются методы снижения размерности путем перехода в низкоразмерное латентное пространство.

**Определение 2.1.** Параметрическая функция  $\varphi_1 : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}^{n \times p}$ , переводящая исходные данные в латентное пространство, называется **функцией кодирования**.

**Определение 2.2.** Функция  $\varphi_2 : \mathbb{R}^{n \times p} \rightarrow \mathbb{R}^{n \times m}$ , переводящая данные из латентного пространства в исходное, называется **функцией восстановления**.

**Определение 2.3.** Функция  $g : \mathbb{R}^{n \times p} \times \mathbb{R}^{n \times p} \rightarrow \mathbb{R}$ , связывающая закономерности в низкоразмерных латентных представлениях, называется **функцией согласования**.

**Определение 2.4.** Согласование — алгоритмическая процедура максимизации функции согласования.

## 2.2 Снижение размерности

Коммутативная диаграмма процедуры выбора прогностической модели имеет вид

$$\begin{array}{ccc}
 \mathbf{X}_{n \times m} & \xrightarrow{f} & \mathbf{Y}_{n \times k} \\
 \varphi_1 \left( \begin{array}{c} \uparrow \varphi_2 \\ \downarrow \end{array} \right. & & \left. \begin{array}{c} \uparrow \psi_2 \\ \downarrow \end{array} \right) \psi_1 \\
 \mathbf{T}_{n \times p} & \xleftarrow{g} & \mathbf{U}_{n \times p}
 \end{array} \tag{4}$$

где  $\varphi_1 : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}^{n \times p}$  — функция кодирования независимых переменных;  $\psi_1 : \mathbb{R}^{n \times k} \rightarrow \mathbb{R}^{n \times p}$  — функция кодирования целевых переменных;  $\varphi_2 : \mathbb{R}^{n \times p} \rightarrow \mathbb{R}^{n \times m}$  — функция восстановления независимых переменных;  $\psi_2 : \mathbb{R}^{n \times p} \rightarrow \mathbb{R}^{n \times k}$  — функция восстановления целевых переменных;  $g : \mathbb{R}^{n \times p} \times \mathbb{R}^{n \times p} \rightarrow \mathbb{R}$  — функция согласования. Матрицы

$$\mathbf{T} = \varphi_1(\mathbf{X}) \in \mathbb{R}^{n \times p}; \quad \mathbf{U} = \psi_1(\mathbf{Y}) \in \mathbb{R}^{n \times p}$$

являются матрицами представлений данных в латентном пространстве низкой размерности.

Оптимальные параметры  $\theta_{\varphi_1}^*, \theta_{\psi_1}^*$  для функций кодирования  $\varphi_1$  и  $\psi_1$  находятся из следующей задачи параметрической оптимизации:

$$(\theta_{\varphi_1}^*, \theta_{\psi_1}^*) = \arg \max_{(\theta_{\varphi_1}, \theta_{\psi_1})} g(\varphi_1(\mathbf{X}; \theta_{\varphi_1}), \psi_1(\mathbf{Y}; \theta_{\psi_1})). \tag{5}$$

Так как параметры функции кодирования подбираются из условия максимизации функции согласования (5), то после перехода в латентное пространство между  $\mathbf{T}$  и  $\mathbf{U}$  существует зависимость

$$\mathbf{U} = h(\mathbf{T}) + \boldsymbol{\eta}, \tag{6}$$

где  $h : \mathbb{R}^{n \times p} \rightarrow \mathbb{R}^{n \times p}$  — функция регрессионной зависимости,  $\boldsymbol{\eta}$  — матрица регрессионных ошибок. Оптимальная функция  $h$  выбирается минимизацией функции ошибки. Используется квадратичная функция потерь  $\mathcal{L}$  на  $\mathbf{T}$  и  $\mathbf{U}$ :

$$\mathcal{L}(h|\mathbf{T}, \mathbf{U}) = \left\| \mathbf{U}_{n \times p} - h(\mathbf{T}_{m \times p}) \right\|_2^2 \rightarrow \min_h. \tag{7}$$

Финальная прогностическая модель имеет вид  $\hat{\mathbf{y}} = \psi_2(h(\varphi_1(\mathbf{x})))$ , то есть

$$f = \psi_2 \circ h \circ \varphi_1. \tag{8}$$

## 2.3 Метод главных компонент

Метод главных компонент (РСА) снижает размерность данных и сохраняет максимальную дисперсию. Линейная модель РСА представляет собой ортогональное линейное преобразование исходного признакового пространства в новое пространство меньшей размерности. Первый базисный вектор строится так, чтобы выборочная дисперсия столбцов проекций матрицы  $\mathbf{X}$  была максимальной:

$$\mathbf{p} = \arg \max_{\|\mathbf{p}\|_2=1} [\mathbf{var}(\mathbf{Xp})], \quad (9)$$

где  $\mathbf{var}(\mathbf{Xp}) = \frac{1}{n}(\mathbf{Xp})^T \mathbf{Xp}$  обозначает выборочную дисперсию. Последующие базисные векторы находятся итеративно после вычитания проекции на все найденные ранее.

Функция кодирования  $\varphi_1 : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}^{n \times p}$  имеет вид

$$\varphi_1(\mathbf{X}) = \underset{n \times m}{\mathbf{X}} \cdot \underset{m \times p}{\mathbf{P}}^T, \quad (10)$$

где  $\mathbf{P} = [\mathbf{p}_1, \dots, \mathbf{p}_p]$ . Метод РСА не согласует независимые переменные и целевые переменные. Из-за этого зависимости в обоих пространствах не учитываются.

## 2.4 Метод частичных наименьших квадратов

Метод частичных наименьших квадратов восстанавливает связь между двумя наборами данных  $\mathbf{X}$  и  $\mathbf{Y}$ . Алгоритм проецирует  $\mathbf{X}$  и  $\mathbf{Y}$  на латентное пространство  $\mathbb{R}^p$  меньшей размерности. PLS находит матрицы исходных данных  $\mathbf{X}$  и  $\mathbf{Y}$  в латентном пространстве  $\mathbf{T}$  и  $\mathbf{U}$  соответственно. Матрица объектов  $\mathbf{X}$  и целевая матрица  $\mathbf{Y}$  проецируются на латентное пространство следующим образом:

$$\underset{n \times m}{\mathbf{X}} = \underset{n \times p}{\mathbf{T}} \cdot \underset{p \times m}{\mathbf{P}}^T + \underset{n \times m}{\mathbf{F}}, \quad (11)$$

$$\underset{n \times k}{\mathbf{Y}} = \underset{n \times p}{\mathbf{U}} \cdot \underset{p \times k}{\mathbf{Q}}^T + \underset{n \times k}{\mathbf{E}}, \quad (12)$$

где  $\mathbf{T}$  и  $\mathbf{U}$  — матрицы описания объектов и исходов в латентном пространстве;  $\mathbf{P}$  и  $\mathbf{Q}$  — матрицы перехода из латентного пространства в исходное;  $\mathbf{F}$ ,  $\mathbf{E}$  — матрицы остатков.

В методе PLS функции кодирования имеют вид

$$\varphi_1(\mathbf{X}) = \mathbf{XW}_x, \quad \psi_1(\mathbf{Y}) = \mathbf{YW}_y,$$

где матрицы весов  $\mathbf{W}_x \in \mathbb{R}^{m \times p}$ ,  $\mathbf{W}_y \in \mathbb{R}^{k \times p}$  находятся путем максимизации функции согласования  $g(\mathbf{XW}_x, \mathbf{YW}_y) = \mathbf{Cov}(\mathbf{XW}_x, \mathbf{YW}_y)^2$ :

$$(\mathbf{W}_x, \mathbf{W}_y) = \arg \max_{\mathbf{W}_x, \mathbf{W}_y} [\mathbf{Cov}(\mathbf{XW}_x, \mathbf{YW}_y)^2], \quad (13)$$

где  $\mathbf{Cov}(\mathbf{XW}_x, \mathbf{YW}_y)$  — выборочная ковариация.

Функции восстановления принимают вид

$$\varphi_2(\mathbf{T}) = \mathbf{TP}^T, \quad \psi_2(\mathbf{U}) = \mathbf{UQ}^T.$$

## 2.5 Канонический анализ корреляций

Канонический анализ корреляций находит два набора базисных векторов  $\{\mathbf{w}_{\mathbf{x}_i}\}_{i=1}^p$ ,  $\mathbf{w}_{\mathbf{x}} \in \mathbb{R}^m$ , и  $\{\mathbf{w}_{\mathbf{y}_i}\}_{i=1}^p$ ,  $\mathbf{w}_{\mathbf{y}} \in \mathbb{R}^k$ , один для матрицы  $\mathbf{X}$ , другой для матрицы  $\mathbf{Y}$ , так чтобы коэффициент корреляции между проекциями переменных на эти базисные векторы был максимальным. Функция согласования для ССА имеет вид

$$g(\mathbf{X}\mathbf{W}_{\mathbf{x}}, \mathbf{Y}\mathbf{W}_{\mathbf{y}}) = \text{corr}(\mathbf{X}\mathbf{W}_{\mathbf{x}}, \mathbf{Y}\mathbf{W}_{\mathbf{y}}),$$

где  $\text{corr}(\mathbf{X}\mathbf{w}_{\mathbf{x}}, \mathbf{Y}\mathbf{w}_{\mathbf{y}})$  – коэффициент корреляции между векторами.

Таким образом, функции кодирования имеют вид

$$\varphi_1(\mathbf{X}) = \mathbf{X}\mathbf{W}_{\mathbf{x}}, \quad \psi_1(\mathbf{Y}) = \mathbf{Y}\mathbf{W}_{\mathbf{y}},$$

где первые столбцы матриц весов находятся как векторы, максимизирующие функцию согласования  $g$ . Далее ищутся векторы, максимизирующие  $g$ , но с ограничением, что они не коррелируют с первой парой векторов. Процедура продолжается до тех пор, пока число векторов не станет равным  $p$ .

## 2.6 Нелинейный канонический анализ корреляций

Нелинейный канонический анализ корреляций — нелинейная модификация ССА. Метод Деер ССА преобразует исходные данные с помощью нейронной сети таким образом, что результирующее представление становится согласованным. В данной работе рассматриваются следующие нелинейные функции кодирования и восстановления:

$$\begin{aligned} \mathbf{T} &= \varphi_1(\mathbf{X}) = \mathbf{W}_{\mathbf{x}}^L \sigma(\dots \sigma(\mathbf{W}_{\mathbf{x}}^2 \sigma(\mathbf{X}\mathbf{W}_{\mathbf{x}}^1)) \dots), \\ \mathbf{U} &= \psi_1(\mathbf{Y}) = \mathbf{W}_{\mathbf{y}}^L \sigma(\dots \sigma(\mathbf{W}_{\mathbf{y}}^2 \sigma(\mathbf{Y}\mathbf{W}_{\mathbf{y}}^1)) \dots), \\ \mathbf{X} &= \varphi_2(\mathbf{T}) = \mathbf{W}_{\mathbf{t}}^L \sigma(\dots \sigma(\mathbf{W}_{\mathbf{t}}^2 \sigma(\mathbf{T}\mathbf{W}_{\mathbf{t}}^1)) \dots), \\ \mathbf{Y} &= \psi_2(\mathbf{U}) = \mathbf{W}_{\mathbf{u}}^L \sigma(\dots \sigma(\mathbf{W}_{\mathbf{u}}^2 \sigma(\mathbf{U}\mathbf{W}_{\mathbf{u}}^1)) \dots). \end{aligned}$$

Каждая функция представляет нейронную сеть с  $L$  скрытыми слоями.

Требуется найти такие параметры, при которых функция согласования  $g$  достигает своего максимума

$$g(\mathbf{T}, \mathbf{U}) \rightarrow \max_{\mathbf{W}}, \quad (14)$$

где  $\mathbf{W} = \{\{\mathbf{W}_{\mathbf{x}}^i\}_{i=1}^L, \{\mathbf{W}_{\mathbf{y}}^i\}_{i=1}^L, \{\mathbf{W}_{\mathbf{t}}^i\}_{i=1}^L, \{\mathbf{W}_{\mathbf{u}}^i\}_{i=1}^L\}$ .

## 3 Вычислительный эксперимент

Цель вычислительного эксперимента – сравнительный анализ рассматриваемых моделей. Рассматриваются данные, для которых сложность класса линейных методов неадекватно низка. Нелинейные модели позволяют получить точный прогноз при адекватной сложности. В рамках вычислительного эксперимента написан программный комплекс для решения поставленных задач [17].




Рис. 1: Зашумленные изображения из набора данных MNIST

### 3.1 Анализ нелинейных зависимостей в задаче фильтрации шума

Проведем сравнение качества Deep CCA и CCA на задаче классификации зашумленных цифровых изображений, представленных на рис. 1. Для этого используется набор данных MNIST [16], который состоит из 70 000 цифровых изображений  $28 \times 28$  пикселей рукописного написания цифр. Предлагается получить два новых набора данных  $\mathbf{X}$  и  $\mathbf{Y}$  следующим образом. Первый набор получается поворотом исходных изображений на угол в диапазоне  $[-\frac{\pi}{4}, \frac{\pi}{4}]$ . Для получения второго набора данных для каждой картинке из первого набора данных ставится в соответствие случайным образом картинка с той же цифрой, но с добавлением независимого случайного шума, распределенного равномерно на отрезке  $[0, 1]$ .

Применив к двум новым наборам данных DeepCCA или CCA, получаем новое низкоразмерное признаковое пространство, которое игнорирует шумы в исходных данных. Таким образом, получаем функции кодирования  $\varphi_1$  и  $\psi_1$  для исходных наборов данных. На новых признаках, полученных разными моделями (DeepCCA и CCA), для первого набора данных, то есть на данных после применения функции кодирования

Таблица 1: Точность классификации линейного SVM для алгоритмов Deep CCA и CCA

Скольльзящий контроль	Deep CCA ( $L = 3$ )	CCA
Валидация	92,74%	76,21%
Тест	92,14%	76,07%



Рис. 2: Набор данных MNIST, в котором каждое изображение разделено пополам

$\varphi_1$  к первому набору исходных данных, обучим линейный SVM-классификатор. Показателем эффективности будет точность классификации линейного SVM на тестовых данных. В случае построения адекватного скрытого пространства полученные образы объектов будут линейно разделимы. Результаты эксперимента приведены в табл. 1. Модель Деер ССА представляет собой нейронную сеть с  $L = 3$  скрытыми слоями. Точность классификации нелинейной модели существенно выше линейного алгоритма ССА.

### 3.2 Анализ нелинейных моделей для восстановления изображений

Для анализа процедуры согласования проведен вычислительный эксперимент с предложенными нелинейными моделями. Для снижения размерности пространства используются нейросетевые модели автокодировщика с согласованием скрытого пространства (14). В качестве базовых моделей используются модель автокодировщика без согласования скрытых пространств, а также линейный PLS. В качестве исходного набора данных используется набор данных MNIST [16]. Каждое изображение поделено на левую и правую части, как показано на рис. 2. Модель по левому изображению восстанавливает правое изображение.

Модель EncNet1 — нейронная сеть с нелинейными функциями активации, которая обучается на данных после преобразования их автоэнкодером. Модель LinNet1 — нейронная сеть с одним линейным слоем, которая также обучается на преобразованных данных. Для EncNet1 и LinNet1 автоэнкодеры для объектов и ответов используют совместную функцию потерь, которая связывает выходы энкодеров. Модели EncNet2 и LinNet2 устроены аналогично EncNet1 и LinNet1 соответственно, но в автоэнкодерах нет совместной функции потерь. Модель DumbNet — нейронная сеть, которая обучается на исходных данных и имеет такую же структуру, что и EncNet, то есть имеет такое же число слоев и в каждом слое такое же количество нейронов, что и у EncNet.

Для оценки качества моделей вычислялась среднеквадратичная ошибка. Примеры восстановленных изображений показаны на рис. 3. Качество моделей, а также их сложность представлены в табл. 2. На рис. 3 продемонстрировано, что предложенные модели EncNet и LinNet позволяют получить более четкие и различимые изображения, в отличие от базовой нелинейной модели DumbNet и линейной модели PLS. Несмотря на заметное улучшение визуального качества изображений, ошибка






Рис. 3: Пример реконструкции правой части изображения по левой для рассматриваемых моделей

предложенных моделей выше, чем у модели DumbNet. Авторы предполагают, что это связано с тем, что среднеквадратичная ошибка оказалась неадекватной метрикой в пространстве изображений. Нахождение оптимальной метрики для оценки качества предложенных алгоритмов может быть одним из возможных направлений развития текущей работы.

Таблица 2: Квадратичная ошибка для нелинейных моделей в задаче восстановления правой части изображения по левой

	EncNet1	LinNet1	EncNet2	LinNet2	DumbNet	PLS
Число параметров, тыс.	283	239	283	239	283	—
Ошибка на тесте	0,147	0,235	0,149	0,236	0,128	0,188

## 4 Заключение

В работе рассмотрена задача восстановления для сложноорганизованной целевой переменной. Рассмотрены линейные модели согласования образов объектов в скрытом пространстве. При наличии сложных нелинейных зависимостей между независимой и целевой переменной сложности линейной модели оказывается недостаточно. Для построения точного прогноза приводятся нелинейные обобщения рассматриваемых линейных методов. В экспериментах на реальных данных изображений рукописных цифр показана адекватность рассматриваемых нелинейных моделей, а также проведен анализ различных способов согласования.

## Список литературы

- [1] *Rosipal R., Kramer N., Graves A.* Overview and recent advances in partial least squares // Subspace, Latent Structure and Feature Selection: International Statistical and Optimization Perspectives Workshop. – Springer, 2005. P. 34–51.
- [2] *Rosipal R.* Nonlinear partial least squares: An overview // Chemoinformatics and Advanced Machine Learning Perspectives. – IGI Global, 2011. P. 169–189.
- [3] *Nguyen D. V., Rocke D. M.* Tumor classification by partial least squares using microarray gene expression data // Bioinformatics, 2012. Vol. 18. P. 39–50.
- [4] *Worsley K. J.* An overview and some new developments in the statistical analysis of pet and fmri data // Human Brain Mapping, 1997. Vol. 5. P. 254–258.
- [5] *Hulland J. S.* Use of partial least squares (pls) in strategic management research: A review of four recent studies // Strategic Management Journal, 1999. Vol. 20. P. 195–204.
- [6] *Shalamu Abudu P. E., Pagano T. C.* Application of partial least-squares regression in seasonalstreamflow forecasting // Journal of Hydrologic Engineering, 2010. Vol. 15. P. 612–623.
- [7] *Szedmak S. R., Hardoon D. R., Shawe-taylor J. R.* Canonical correlation analysis: An overview with application to learning methods // Neural computation, 2004. Vol. 16. P. 2639–2664.
- [8] *Schechner Y. Y., Kidron E., Elad M.* Pixels that sound // IEEE Computer Society, 2005. Vol. 1. P. 88–95.
- [9] *Sun S., Ji L., Ye J.* A least squares formulation for canonical correlation analysis // Proceedings of the 25th international conference on Machine learning. – ACM, 2008. P. 1024–1031.

- [10] *Qin S. J., McAvoy T. J.* Nonlinear pls modeling using neural networks // Computers Chemical Engineering, 1992. Vol. 16. P. 379–391.
- [11] *Chen D. Z., Yan X. F., Hu S. X.* Chaos-genetic algorithms for optimizing the operating conditions based on rbf-pls model // Computers and Chemical Engineering, 2003. Vol. 27. P. 1393–1404.
- [12] *Hidden M., McKay B., Montague G.* Non-linear partial least squares using genetic programming // Genetic Programming. – Morgan Kaufmann San Francisco, 1998. P. 128–133.
- [13] *Chen D. Z., Yan X. F., Hu S. X.* Deep canonical correlation analysis // Proceedings of the 30th International Conference on Machine Learning. – PMLR, 2013. P. 1247–1255.
- [14] *Lai P. L., Fyfe C.* Kernel and nonlinear canonical correlation analysis // International Journal of Neural Systems, 2000. Vol. 10. P. 365–377.
- [15] *Yan F., Mikolajczyk K.* Deep correlation for matching images and text // Computer Vision and Pattern Recognition, 2015. Vol. 4. P. 3441–3450.
- [16] *LeCun Y., Cortes C., Burges C.* The MNIST dataset of handwritten digits, 1998. <http://yann.lecun.com/exdb/mnist/index.html>.
- [17] *Yaushev F. Yu., Isachenko R. V.* Модели согласования скрытого пространства в задаче прогнозирования. 2020. <https://github.com/Fyaushev/2020-Project-72>.